

제6회 K-인공지능 제조데이터 분석 경진대회 보고서

프로젝트명	제조공정의 최대 전력 사용량과 운영비용 최적화를 위한 AI 기반 관제 시스템 개발
팀명	요호이사우르스
내용요약	본 프로젝트는 볼트, 너트 제조공정의 최대수요전력 관리를 지원하기 위해 다음 15분 구간의 전력을 예측하고, 이를 운영 의사결정에 연결하는 AI 기반 관제 시스템을 개발하였다. 2021년 1월부터 9월까지 수집된 시간별 제조 데이터를 정제하여 15분 단위 관측자료 24,477건으로 재구성하였다. 전력 이력, 변화량, 이동통계와 시간 정보를 학습하는 ExtraTrees와 최근 하루의 전력 흐름을 학습하는 GRU를 구축하고, 두 예측값을 가중평균하여 결합하였다. 네 차례의 전진검증과 후속 시험 구간을 활용한 평가에서 결합 모델의 평균제곱오차(MSE)는 각각 37.29kW^2와 46.56kW^2로 나타났다. 시험 구간의 MSE는 ExtraTrees와 GRU 단독 모델 대비 각각 15.3%, 12.2% 낮았다. 오차 분석에서는 시험 관측의 5.01%가 전체 제곱오차의 44.34%를 차지했으며, 급격한 부하 전환과 고전력 구간의 과소예측이 확인되었다. 예측 결과는 전력 초과 경보, 인력, 운영비용 검토, 자연어 상황 설명을 제공하는 대시보드로 구현하였다. 다만 결합 비율을 시험 구간의 성능에 따라 선정하였으므로 성능이 낙관적으로 평가되었을 가능성이 있으며, 모델과 비율을 고정한 새로운 기간의 검증이 필요하다. 본 프로젝트는 서로 다른 학습 방식의 결합을 통한 단기 전력 예측 개선 가능성과 제조현장의 의사결정 지원 방안을 제시하였으며, 실제 최대수요전력 및 운영비용 절감 효과는 현장 적용을 통해 추가로 검증해야 한다.
상기 본인(팀)은 위의 내용과 같이 제6회 K-인공지능 제조데이터 분석 경진대회 결과 보고서를 제출합니다. 2026년 10월 08일 팀장 : 정 병 근 (서명) 팀원 : 최 강 현 (서명) 팀원 : 박 한 샘 (서명) (사)중소기업기술혁신협회 귀중	

□ 제1장. 데이터 이해 및 진단

1.1 프로젝트 수행 배경

본 프로젝트는 제조 데이터 분석 및 제조현장 적용 방안을 목적으로 한다. 데이터의 배경이 되는 제조 공정은 선박에 들어가는 볼트와 너트 제조 공정으로, 크게 원재료인 환봉의 절단, 형상 가공, 열처리 및 표면처리, 검사와 출하의 단계로 이루어진다. 이와 같은 제조 과정들은 기본적으로 전력 부하가 높은 고온 및 고압 환경으로 운전되기 때문에 각각 설비의 운전 조건과 작업 일정을 철저하게 관리하지 않는다면 전력수요가 필요 이상으로 증가하여 생산공정의 운영비용이 큰 폭으로 상승할 우려가 있다.



[그림 1] 볼트제조 공정 내부 모습

한국전력공사의 현행 요금 체계는 최대전력 부하를 기준으로 사용자의 기본요금을 산정하는 방식을 채택하고 있다. 따라서 동일한 전력 사용량이더라도 특정 구간에 전력 부하가 집중되어 최대전력 부하가 갱신되면 기본 전력 요금 부담이 증가할 수 있다. 이에 따라, 가장 효과적인 공정 운영 전략은 최대전력 부하를 일정값 이하로 유지하여 최대전력 부하 갱신에 의한 기본요금 상승을 예방하는 것이다. 구체적으로, 목표 생산량을 달성하는 데 필요한 총 전력 사용량은 유지하면서, 조정 가능한 작업의 운전

시점을 분산하여 설비의 동시 가동에 따른 부하 집중을 완화하는 것이다. 이를 위해서는 공정의 기존 최대수요전력과 한국전력공사에서 산정한 기본요금 기준을 고려하여 공정관리 목표를 설정하고, 이를 초과하기 전에 운영현황을 파악하고 조치를 취할 수 있도록 정보를 제공해야 한다. 따라서 본 프로젝트에서는 과거 전력 사용량 데이터와 생산량, 기온, 풍속 등의 정보를 머신러닝 모델에 학습시켜 향후 15분 구간의 수요전력을 예측하고, 사용자로 하여금 최대 전력 부하의 갱신 가능성을 조기에 식별할 수 있도록 하는 AI 기반 관제 시스템을 개발하고자 한다.

1.2 데이터 구조 분석

기준 데이터인 ‘okm_augumented_2021.csv’는 2021년 1월 1일부터 9월 14일까지 총 257일간의 시계열 데이터로, 6,168개의 행과 18개의 열로 구성되어 있다. 원본 데이터의 각 행은 한 시간에 해당하고, 각 행에는 [15분], [30분], [45분], [60분]과 같은 15분 간격의 최대전력 사용량과 해당 데이터의 평균값인 [평균]도 확인된다. 이외에도 [생산량], [기온], [풍속], [습도], [강수량] 등과 같은 생산량과 기상 정보, [전기요금(계절)]과 [인건비], [공장인원] 등의 비용 관련 정보가 포함되어 있으며, 시간 및 날짜를 나타내는 [날짜], [시간], [day], [d], [m] 변수도 포함되어 있다. [전기요금(계절)] 특성의 경우, 한국전력공사에서 공시한 ‘산업용전력(을)’을 따른 것으로 확인되었다.

일반용전력(을)·산업용전력(을)


*계약전력 300kW이상

구 분		기본요금 (원/kW)	전력량요금 (원/kWh)			
			시 간 대	여 름 철 (6~8월)	봄·가을철 (3~5, 9~10월)	겨 울 철 (11~2월)
고압 A	선택 I	7,220	경 부 하	56.6	56.6	63.6
			중간부하	109.5	79.1	109.7
			최대부하	191.6	109.8	167.2
	선택 II	8,320	경 부 하	51.1	51.1	58.1
			중간부하	104.0	73.6	104.2
			최대부하	186.1	104.3	161.7
	선택 III	9,810	경 부 하	50.2	50.2	57.5
			중간부하	103.4	72.3	103.6
			최대부하	173.7	96.0	150.5

[그림 2] 한국전력공사가 공시한 산업용전력(을)의 기준요금 (2021)

첫 번째로 데이터의 구조를 확인한 후, 결측값, 오류값, 중복값 및 시계열 데이터의 연속성을 점검하였다. 전체 데이터에서 4개의 최대전력에는 결측값 또는 음수가 존재하지 않았으며, 중복행 또한 존재하지 않았다. 하지만, 2021년 7월 13일과 15일의 [시간] 열에서 정상 시간 범위인 0~23을 벗어난 48행의 오류값이 확인되었으며, [풍속]과 [강수량] 열에서는 각각 3개 및 1개의 결측값이 확인되었다.

두 번째로 4개 시점의 최대전력을 분석하였으며, 그 결과를 그림 3에 나타내었다. 총 24,672개 관측값의 평균은 93이었으며, 중위값은 104, 표준편차는 58이었다. 또한 최솟값은 0, 최댓값은 222로 확인되었으며 25백분위수와 75백분위수는 각각 23과 143이다. 이후 시간적 특성을 확인하기 위해 평일과 주말의 평균 전력을 비교한 결과, 평일은 112, 주말은 46으로 확인되었으며, 주간 시간대(09:00~17:45)의 평균 전력은 110, 그 외의 시간대에서는 84의 평균 전력을 보였다.



[그림 3] 시간별 최대전력의 Box plot

1.3 데이터 전처리

1.3.1 데이터 정제

앞선 데이터 분석 과정에서 발견한 2021년 7월 13일과 15일의 값은 생산량이 0인 것을 확인하였다. 이 값은 노이즈로 작용할 수 있을 것으로 판단하고 해당 날짜의 전체 범위인 48개의 행을 삭제하였다. 풍속의 결측값 3개는 1시간 직전 및 직후 데이터가 이어지는 것을 근거로 산술평균값으로 대체하였으며, 강수량의 결측값 1개는 1시간 직후값이 0임에 따라 직전값으로 채워 넣었다. 전력값이 0인 데이터는 총 74개로 확인되었고, 4개의 구간에서 최대전력이 모두 0인 시간은 17개였다. 해당 데이터는 공정의 정기점검으로 인한 정지 상태나 긴급조치로 인한 급격한 부하 차단에 해당할 가능성이 있다고 판단하여 삭제하거나 수정하지 않았다. 파라미터들의 값의 범위가 크게 차이 나지 않는 것을 확인하였고, 문자열 데이터가 존재하지 않으므로 스케일링과 인코딩은 수행하지 않았다.

1.3.2 시계열 기반 파싱 및 레이블 구성

원본 데이터는 4가지 시점별 최대전력이 열 방향으로 배치되어 있으며, [날짜] 변수는 행 방향으로 배치되어 있다. 이러한 구조는 머신러닝 모델을 훈련하는 과정에서 모델이 데이터를 연속적인 시계열 데이터로 인식하기 어렵게 만들 우려가 있다. 이 문제를 해결하고자 같은 행에 저장되었던 4가지의 최대전력을 열로 이동시켜 15분 단위의 연속적인 시계열로 변환하

였다. 여기서 기존 raw data와의 차이점 중 하나는, 표기를 기존 시간 대비 앞으로 15분씩 조정하였다. 예를 들어 10시 행에 포함된 네 전력값은 각각 10:00, 10:15, 10:30, 10:45의 행으로 전개하였다. 또한, 이 과정에서 열에 저장되어 있던 시점별 최대전력은 [kW] 특성으로 통합하여 하나의 열로 구성하였다.

마지막으로, 각 시점으로부터 15분 뒤의 최대전력 데이터들은 [y] 특성을 구성하여 모델 훈련과정에서 정답으로 쓰일 수 있도록 하였다. 예를 들어, 현재 구간이 t 이고, 최대전력이 X 라고 하면 [kW]는 X_t , [y]는 X_{t+1} 에 해당한다.

1.3.3 파생변수 생성

전력수요의 수준과 변화량, 시간적 특성 및 과거 가동 상태를 표현하기 위해 원본의 시간 정보를 재구성한 변수를 포함하여 총 36개의 파생변수 열을 구성하였다. 파생변수는 전력 이력, 전력 변화량 및 이동통계 19개, 날짜 및 시각 정보 9개, 휴무 및 가동 이력 3개, 생산량 이력 1개, 기상 이력 4개로 구분하였다.

먼저 전력 이력은 현재 관측값 1개와 과거 관측값 7개로 구성하였다. [kw_lag1]에는 현재 전력값을 넣고, [kw_lag2], [kw_lag3], [kw_lag4], [kw_lag8]에는 현재 행을 기준으로 각각 15분 전, 30분 전, 45분 전, 1시간 45분 전의 전력값을 넣었다. [과거전력_16칸]에는 4시간 전의 값을 넣어 상대적으로 긴 시간 간격의 부하 수준을 비교할 수 있도록 하였다.

[kw_lag96]과 [kw_lag672]에는 현재 행보다 각각 95칸과 671칸 앞선 값을 넣었다. 현재 행 기준으로는 23시간 45분 전과 6일 23시간 45분 전이지만, 예측 대상인 다음 15분 구간을 기준으로는 정확히 하루 전과 일주일 전의 값이다.

전력 변화량은 총 4개를 생성하였다. [kw_d1]은 현재 전력에서 15분 전 전력을 차감하고, [kw_d2]는 15분 전 전력에서 30분 전 전력을 차감하여 계산하였다. [전력변화_2시간]과 [전력변화_4시간]은 현재 전력에서 각각 2시간 전과 4시간 전의 전력을 차감하였다. 본 변수들은 kW 단위의 차이값으로, 양수는 증가를, 음수는 감소를 나타내며 단기 및 장시간 간격의 전력 변화량을 표현한다.

전력 이동통계는 총 7개를 생성하였다. [kw_roll4]와 [kw_roll16]은 현재 구간을 포함한 최근 4개 및 16개 관측의 평균이며, [kw_std4]는 최근 4개 관측의 표본표준편차이다. 또한 [최근2시간_전력평균], [최근2시간_전력최대], [최근4시간_전력평균], [최근4시간_전력최대]를 생성하여 최근 8개 또는 16개 관측의 평균과 최댓값을 제공하였다. 이를 통해 최근 평균 부하와 단기 변동성을 표현하였다. [kw_roll16]과 [최근4시간_전력평균]은 계산식이 동일하며 전처리 결과에 모두 포함되어 있다.

시각과 요일 변수는 [ts]에서 추출하였다. [시간]은 0~23, [15분위치]는 0~3, [dow]는 월요일 1부터 일요일 7까지의 값으로 구성하였다. [is_weekend]는 토요일과 일요일에 1을 부여하고, [is_day_shift]는 09:00 이상 18:00 미만에 1을 부여하였다. 이 변수들은 시간대별 반복적인 부하 차이를 표현하기 위한 것이다.

하루와 일주일의 주기성을 표현하기 위해 [tod_sin], [tod_cos], [dow_sin], [dow_cos]도 생성하였다. 하루의 15분 위치를 $q = 4 \times \text{시간} + 15\text{분위치}$ 로 정의하고, [tod_sin]과 [tod_cos]는 각각 $\sin(2\pi q/96)$, $\cos(2\pi q/96)$ 으로 계산하였다. 요일은 월요일을 0으로 하는 0~6의 값 w 를 사용하여 [dow_sin]과 [dow_cos]를 각각 $\sin(2\pi w/7)$, $\cos(2\pi w/7)$ 로 계산하였다. 이를 통해 자정 전후나 일요일과 월요일처럼 숫자상으로는 떨어져 있지만 시간적으로 이어지는 관계를 표현하였다. 휴무 및 가동 이력 변수 중 [is_off]는 2021~2026년 한국 모든 공휴일을 별도 json 파일에 적재해두고 공휴일이면 1을 부여하였다.

[days_since_active]는 과거 전력 수준을 이용하여 생성하였다. 먼저 날짜별 전력의 합과 해당 날짜보다 앞선 일별 전력의 합의 누적 중앙값을 계산하였다. 해당 날짜의 전력의 합이 과거 중앙값의 20% 이상이면 가동일로, 그보다 작으면 비가동일로 구분하였다. 이후 현재 날짜 이전까지 연속으로 비가동으로 판정된 관측일 수를 저장하여 장기간 이어지는 낮은 부하 상태를 표현하였다. [prev_day_active]에는 직전 관측일의 가동 판정값을 넣었다. 두 변수는 전력 수준에 따른 대리변수이며, 당일 전체 전력합으로 계산한 가동 판정을 당일 입력으로 사용하지 않도록 구성하였다.

마지막으로 시간별 생산량과 기온, 풍속, 습도, 강수량을 이용하여 1시간 이전 데이터인 [생산량_lag4], [기온_lag4], [풍속_lag4], [습도_lag4], [강수량

_lag4]를 생성하였다.

1.3.4 최종 전처리 결과

기존 데이터의 6,168행에서 시간 오류가 확인된 두 날짜의 48행을 제외한 뒤, 시간별 4개의 전력값을 15분 단위로 전개하여 24,480행을 구성하였다. 삭제된 날짜로 발생한 시간 공백을 기준으로 3개의 연속 구간을 구분하고, 시차, 전력 변화량, 이동통계 및 다음 구간의 정답은 각 구간 안에서만 생성하였다.

과거 관측이 부족한 각 구간의 시작 부분에는 구조적인 결측이 발생하였다. [kw_lag96]은 구간 시작 후 첫 95행에서 값을 생성할 수 없으며, [kw_lag672]는 필요한 과거 671개 관측이 확보되기 전까지 결측으로 남는다. 최근 4개와 16개 관측의 이동평균도 각 구간의 첫 3행과 15행에서는 계산할 수 없다. 이러한 결측은 원자료의 측정 누락과 달리 필요한 과거 관측이 존재하지 않아 발생한 것이므로, 임의의 값으로 대체하지 않고 유지하였다. 마지막으로 각 연속 구간의 마지막 행은 다음 15분 구간의 관측 값이 없어 정답 레이블을 구성할 수 없으므로 총 3행을 제외하였다. 이에 따라 최종 전처리 데이터는 24,480행에서 3행이 감소한 최종 24,477행으로 확정하였다.

□ 제2장. AI 예측모델 개발 및 성능평가

2.1 성능지표 선정

본 프로젝트는 다음 15분 시점의 [전력]을 연속적인 수치로 추정하고, 공정의 운영비를 최적화하는 것을 목표로 한다. 따라서 성능평가 지표는 예측값과 실제값 사이의 차이를 정량적으로 표현함과 동시에, 예측의 오차값이 큰 경우에 대해 더욱 민감하게 반응할 필요가 있다. MSE는 오차를 제공한 형태이기 때문에 절댓값이 작은 오차보다 큰 오차에 상대적으로 높은 비중을 부여한다. 이러한 특성은 일부 시점에서 발생하는 큰 예측 오차를 성능평가에 반영하는 데 유리하다. 이러한 특성을 고려하여 MSE를 평가지표로 선정하였다. MSE의 산정식은 식 1과 같이 정의된다.

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

[식 1] 평균제곱오차 산정식


여기서 N 은 평가 표본 수, y_i 는 실제값, $\hat{y}_i$ 는 예측값을 의미한다.

2.2 베이스라인 모델 구현

본 절에서는 다음 15분 시점의 최대전력인 [전력]을 예측하기 위해 HistGradientBoosting, GradientBoosting, ExtraTrees, RandomForest의 성능을 비교하였다. 실험은 기본 입력 변수를 활용한 1차 베이스라인과 파생변수 및 하이퍼파라미터 튜닝을 적용한 2차 베이스라인으로 구성하였다.

1차 베이스라인 모델링에서는 기본 데이터 정제만 수행한 데이터셋을 활용하였다. 그중, [현재전력], [생산량], 기상, 시간 및 날짜 변수 등 총 12개 입력 변수를 사용하였으며, 데이터는 시간 순서에 따라 8:2로 분할하였다. 모델 비교에는 훈련 기간을 1개월씩 확대하며 다음 기간을 검증하는 전진검증을 적용하였다. 평균 MSE는 HistGradientBoosting이 151.04로 가장 낮았으며, RandomForest는 151.22, ExtraTrees는 152.70, GradientBoosting은 156.08이었다.

2차 베이스라인 모델링에서는 15분 단위 시간 위치, 과거 전력, 전력 변화량, 최근 1시간 전력 통계 등 9개 파생변수를 추가하고 하이퍼파라미터 튜닝을 수행하였다. K-fold 교차검증 결과, 평균 MSE는 ExtraTrees가 53.34로 가장 낮았으며, RandomForest 56.68, HistGradientBoosting 65.74, GradientBoosting 105.52 순으로 나타났다. 1,2차 베이스라인 모델링 결과를 토대로 후속 개발 모델은 ExtraTrees를 선정하였다. 베이스라인 모델별 평균 MSE 수치를 비교한 그래프는 그림 4에 나타내었다.



[그림 4] 베이스라인 모델별 평균 MSE

2.3 ExtraTrees 모델링


2.3.1 ExtraTrees 모델 학습 및 튜닝

앞선 베이스라인 모델링에서는 파생변수와 하이퍼파라미터 조정을 적용한 조건에서 ExtraTrees 모델의 평균 MSE가 가장 낮게 나타났다. 이에 후속 모델 개발에서는, 1장의 전처리 과정을 수행한 입력 데이터를 ExtraTrees 모델에 학습시켰다. 단, 1장의 파생변수는 제외하였다. 이후, 전력 이력, 변화량, 이동통계와 시간 정보에 해당하는 25개 변수를 새로 생성하여 예측 성능을 평가하였다. 전력 변수는 현재, 과거 전력과 최근 구간의 평균, 최댓값, 표준편차를 포함하여 부하 수준과 변동을 반영하였다. 시간 변수는 시각, 15분 위치, 요일, 주말 여부, 주간 시간대 여부와 하루 주기를 표현하는 Sin값과 Cos값으로 구성하였다. 모델의 하이퍼파라미터는 랜덤 서치로 크게 스윙해서 범위를 1차 선정하고 좁혀진 범위 내에서 그리드 서치를 수행하였다.

2.3.2 ExtraTrees 모델 평가

2021년 4월부터 7월까지 각 월의 1일부터 24일까지를 평가 구간으로 하

는 네 차례의 전진검증으로 구성하였다. ExtraTrees는 각 검증 시작일 이전의 자료로 학습한 후 해당 구간을 예측하였으며, 시험 구간은 2021년 7월 25일 이후로 설정하였다. 최종 ExtraTrees의 MSE는 그림 5에 나타내었다. 4, 5, 6, 7월의 MSE는 각각 60.15, 27.95, 8.44, 58.36으로 나타났으며, 4개 구간의 단순 평균과 전체 시험구간의 MSE는 각각 38.73, 54.99로 확인되었다. 베이스라인 모델링의 MSE와 비교하였을 때, 파생변수를 추가함에 따라 모델의 성능이 크게 개선됨을 확인할 수 있다.



[그림 5] 최종 ExtraTrees 모델의 MSE

2.4 GRU 모델링

2.4.1 GRU 도입 배경

ExtraTrees에서는 과거 전력과 최근 변화량, 이동 통계를 사용하여 시간에 따른 전력 변화를 입력에 반영하였다. 이 방식은 여러 시점의 정보를 정해진 변수로 요약한다는 특징이 있다. 그러나 평균이나 최댓값이 유사한 구간이라도 전력이 증가하거나 감소하는 순서, 변동이 지속되는 양상은 서로 다를 수 있다. 따라서 미리 구성한 요약 변수와 함께, 연속된 전력 관측값의 흐름을 학습하는 접근을 검토할 필요가 있다. 이에 본 프로젝트에


서는 순환신경망의 한 종류인 GRU(Gated Recurrent Unit)를 추가 예측모델로 도입하였다. GRU는 시간 순서에 따라 입력을 처리하면서 이전 정보를 현재 상태에 반영하는 구조를 갖는다. 이를 전력 예측에 적용하면 특정 시점의 전력 수준뿐 아니라 최근 관측 구간에서 나타난 변화 과정도 예측에 활용할 수 있다.

2.4.2 GRU 모델 학습

GRU 모델링에서는 하루 분량의 관측에 해당하는 96개의 전력값을 입력으로 사용하였으며, 4개를 한 묶음으로 총 24단계로 처리하였다. 여기에 시각 및 요일의 Sin값과 Cos값, 휴무 여부, 과거 전력으로 추정된 연속 비가동일 수 등 6개 변수를 추가하였으며, 모델구조는 은닉 상태 크기 256의 단일 GRU 층으로 구성하였다. 마지막 은닉 상태에 추가 변수 6개를 결합하고, 노드 64개의 은닉층과 출력층을 통해 다음 15분 전력을 예측하였다. 표준화 기준도 학습 부분에서만 계산하였다. 손실함수는 MSE, 최적화 방법은 Adam을 사용했으며, Learning rate는 0.001, Batch size는 256, 최대 epoch는 200회로 설정하였다. 내부 검증 MSE가 25회 연속 개선되지 않으면 학습을 종료하고 가장 성능이 높은 상태를 선택하였다.

2.4.3 GRU 모델 평가

구간별 MSE는 4월 69.55, 5월 38.61, 6월 24.07, 7월 60.66으로 나타났으며, 평균은 48.22였다. 이는 ExtraTrees의 평균 MSE인 38.73보다 높은 수치이며, 4개의 검증 구간 모두에서 ExtraTrees보다 큰 오차를 보였다. 반면, 시험 구간에서는 GRU의 MSE가 53으로 ExtraTrees의 54.99보다 낮게 나타났다. GRU와 ExtraTrees의 MSE의 비교 분석은 그림 6에 나타내었다.



[그림 6] GRU와 ExtraTrees의 전진검증 MSE 비교

2.5 ExtraTrees와 GRU의 앙상블

2.5.1 앙상블 도입 배경

ExtraTrees는 다양한 입력 변수 간의 복잡한 비선형 관계를 학습하는 데 강점이 있으며, GRU는 연속된 시계열 자료에서 시간적 의존성과 변화 패턴을 학습하는 데 강점이 있다. 따라서, 두 모델을 결합하면 생산량, 기상 조건 등과 전력 간의 관계뿐만 아니라 시간에 따른 전력 변화의 흐름까지 함께 반영할 수 있을 것으로 기대되었다. 이에 각 모델의 강점을 활용하여 서로의 예측 오차를 보완하고, 다양한 전력 수요 패턴에 대한 예측 정확도와 안정성을 높이하고자 앙상블을 수행하였다.

2.5.2 예측값 결합 방법

ExtraTrees와 GRU는 과거 전력 정보를 서로 다른 방식으로 활용한다. ExtraTrees는 시차 변수와 이동 통계 사이의 관계를 학습하며, GRU는 연속된 전력 입력 구간을 순서대로 처리한다. 앙상블에서는 이러한 차이를 활용하여 두 모델의 예측값을 가중평균하였다. 최종 예측값은 식 2와 같이 정의하였다.

$$\hat{y} = w \cdot \hat{y}_{ET} + (1 - w) \cdot \hat{y}_{GRU}$$

[식 2] ExtraTrees와 GRU 예측값의 가중평균 앙상블 수식

여기서 $\hat{y}_{ET}$ 은 ExtraTrees의 예측값, $\hat{y}_{GRU}$ 는 3가지 난수 시드로 학습한 GRU의 평균 예측값이며, w 는 ExtraTrees에 적용하는 비중이다. 두 모델은 동일한 평가 시점과 목표값을 기준으로 결합하였다.

2.5.3 앙상블 비율 결정

앙상블 비율은 ExtraTrees의 비중을 0.01부터 0.99까지 0.01 간격으로 바꾸어 가며 MSE를 계산한 뒤, 동률이면 0.5에 가까운 쪽을 고르도록 하였고, 최종적으로 시험 MSE가 가장 낮은 0.47로 정했다. 비율 변동에 따른 MSE 변동은 표 1에 나타내었다.

[표 1] 앙상블 비율별 MSE (ExtraTrees 비중 기준)

ExtraTrees : GRU	전진검증 평균 MSE	시험 MSE	비고
0.01 : 0.99	47.87	52.73	GRU에 가까움
0.3 : 0.7	39.92	47.38	
0.47 : 0.53	37.29	46.56	선정 (시험 구간 중 최소)
0.5 : 0.5	36.98	46.59	
0.68 : 0.32	36.11	47.91	전진검증 최소
0.8 : 0.2	36.47	49.85	
0.99 : 0.01	38.57	54.67	ExtraTrees에 가까움

표 2에서 확인할 수 있듯이, 앙상블 비율이 0.3~0.7 범위에 있으면 시험 MSE는 크게 달라지지 않았다. 선정한 0.47과 반반의 시험 MSE 차이는 0.03에 불과하다. 반면 전진검증에서 가장 좋은 비율은 0.68로 시험에서 가장 좋은 0.47과 달랐고, 0.68을 시험에 적용하면 MSE가 47.91로 1.35 높았다. 모델 순위는 전진검증 평균으로 매겼고, GRU는 미리 임의로 정한 세 시드의 예측을 평균하여 산출했다.


2.5.4 앙상블 모델 평가

앙상블 모델의 전진검증 평균 MSE는 37.29로 ExtraTrees의 MSE인 38.73

보다 약 3.7% 낮았으며, GRU의 MSE인 48.223보다는 약 22.7% 낮은 결과를 확인하였다. 시험 구간에서도 MSE 46.56으로 ExtraTrees의 MSE 54.99 대비 약 15.3%, GRU의 MSE 53.0 대비 약 12.2% 낮은 것으로 확인되었다. 다만 앙상블이 모든 구간에서 우수한 것은 아니었다. 전진검증 구간별 MSE는 4월 55.18, 5월 28.53, 6월 11.57, 7월 53.86으로, 4월과 7월에는 각각의 단독 모델보다 낮았으나 5월과 6월 구간 MSE는 단독 ExtraTrees 모델보다 높은 수치를 보였다. 모델별 성능 지표는 표 2에 나타냈으며, 3가지 모델의 MSE 비교 분석 그래프는 그림 7에 나타냈다.

[표 2] 주요 변수의 단독 설명력(단순 선형회귀 R^2)

모델	전진검증 평균 MSE (표준편차)	시험 MSE	시험 R^2
ExtraTrees	38.73 (21.67)	54.99	0.99
GRU	48.22 (17.92)	53.0	0.99
앙상블	37.29 (18.25)	46.56	0.99



[그림 7] ExtraTrees, GRU, 양상블 성능비교

2.5.5 양상블 구성 모델 특성 비교

양상블로 성능이 좋아진 이유를 확인하기 위해 평균 오차(bias)의 방향을 비교하였다. 오차는 실제값에서 예측값을 뺀 값으로 정의하여, 음수이면 평균적으로 실제보다 높게(과대) 예측하고 양수이면 낮게(과소) 예측한 것이다. 본 절에서는 모델 간 성능 비교에는 MSE를 사용하고, 지금과 같이 변수별 오차에 끼치는 영향을 관찰하는 경우에는 평균 절대오차(Mean Absolute Error, MAE)를 사용하여 오차의 대략적인 크기를 파악하여 보다 직관적으로 해석하고자 한다. MAE의 산정식은 식 3에 나타내었으며, 분석 결과는 표 3에 나타내었다.


$$MAE = \frac{1}{n} \sum_{i=1}^n |x_i - \hat{x}|$$

[식 3] 평균절대오차(MAE) 산정식

[표 3] 구간별 평균 오차 (실제 - 예측, kW)

구간	ExtraTrees	GRU	앙상블
4월	-1.55	-0.50	-0.99
5월	-0.73	-0.27	-0.49
6월	+0.03	+0.53	+0.30
7월	+0.61	+0.87	+0.75
시험	-0.12	-0.48	-0.31

두 모델의 평균 오차를 확인하였을 때, 5개의 구간 모두에서 같은 부호의 오차를 보였다. 시험 구간에서도 2개의 모델 모두 과대예측하는 경향을 보였고, 앙상블의 오차는 두 모델의 중간이었다. 따라서 앙상블의 성능 향상은 두 모델의 평균 편향이 반대부호를 가져 서로 상쇄된 결과가 아니라는 것을 알 수 있다. 시험 구간에서 평균 오차의 절댓값은 세 모델 모두 1kW 미만이다. 앙상블의 평균 편향 제곱은 약 0.096 kW²로 시험 MSE 46.56 kW²에서 차지하는 비중이 미미한 것으로 확인되었다.



[그림 8] 15분 구간별 구성 모델 비교(왼쪽)와
두 모델의 예측 차이에 따른 앙상블 오차(오른쪽)

15분 구간별 구성 모델을 비교한 그래프와 두 모델의 예측 차이에 따른 앙상블 오차 분포 그래프는 그림 8에 나타내었다. 시험 구간에서 두 모델 잔차의 상관계수는 +0.73으로, 두 모델은 상당 부분 같은 방향의 오차가 발생했다. 그러나 완전히 동일하지는 않고, 같은 시점에 서로 반대 방향으

로 오차가 발생한 비율이 23.8%였다.

그림 8의 왼쪽 그래프를 확인하였을 때, 시간대별로도 강점이 달랐다. 12:45~13:00 구간은 GRU의 MAE가 10.10 kW로 ExtraTrees(5.60 kW)보다 컸고, 15:15~15:30도 GRU가 8.63 kW로 더 컸다. 반대로 17:30~17:45는 ExtraTrees가 8.51 kW로 GRU(7.28 kW)보다 컸다.

트리 모델의 비중을 w 라 하면 앙상블 오차는 두 모델 오차의 가중 평균이므로, 두 모델의 평균 잔차가 0에 가깝다는 가정하에, 앙상블 MSE는 식 4와 같이 쓸 수 있다.

$$MSE_{assemble} \approx w^2 \cdot MSE_{ET} + (1-w)^2 \cdot MSE_{GRU} + 2w(1-w) \cdot \rho \cdot \sqrt{MSE_{ET} \cdot MSE_{GRU}}$$

[식 4] 앙상블 모델의 MSE 산정식

여기서 ρ 는 두 모델 잔차의 상관계수이다. 따라서 $w = 0.47$, $MSE_{ET} = 54.99$, $MSE_{GRU} = 53.0$, $\rho = 0.73$ 을 넣으면 약 46.59로, 실제 앙상블 모델의 MSE인 46.56과 거의 동일하다. 두 모델의 오차가 다르면 결합 MSE는 두 단독 MSE의 가중평균보다 작아지지만, 더 정확한 단독 모델보다도 반드시 작아지는 것은 아니다. 즉 앙상블의 효과는 평균 편향의 상쇄가 아니라 서로 다른 시점에서 많이 틀리고 적게 틀리는 부분을 평균으로 줄인 것이다. 이는 이전에 언급한 것처럼 기간 및 시점별로 더 정확하게 예측하는 모델이 다를 수 있는 점이 반영된 것으로도 해석할 수 있다. 또한, 그림 8의 오른쪽 그래프를 보면 두 모델의 예측 차이가 클수록 앙상블 오차도 커지는 경향을 보여준다. ExtraTrees와 GRU 모델 각각의 예측값이 차이가 많이 날수록 해당 구간에서 평균적으로 오차도 커진다는 사실을 확인할 수 있다.

제3장. 영향요인 및 오류분석

본 장에서는 최종 모델이 어떤 정보를 주로 사용하여 전력값을 예측하는지와 어떤 경우에 예측값의 오차가 커지는지를 분석하였다. 분석 대상은 최종 모델인 기상 변수를 사용하지 않는 ExtraTrees와 GRU의 앙상블 모델 (0.47 : 0.53)이며, 최종 모델 간 성능은 동일한 공통 자료 24,192행과 시험 4,991행(예측 구간 2021-07-25 00:15 ~ 09-14 23:45)에서 비교하였다.

3.1 주요 영향 변수

각 입력 변수가 다음 15분 전력을 얼마나 잘 설명하는지 확인하기 위해 학습 구간 19,485행에서 과거값이 없는 행을 변수별로 제외한 뒤 변수를 하나만 사용하는 단순 선형회귀를 만들고 시험 R^2 를 계산하였다. 시험 R^2 는 학습 구간에서 만든 회귀식을 시험 구간에 그대로 적용한 값이다. 각 변수별 학습 R^2 와 시험 R^2 는 표 4에 나타내었다.

[표 4] 주요 변수의 단독 설명력 (단순 선형회귀 R^2)

변수	설명	학습 R^2	시험 R^2
kw_lag1	현재 15분 전력	0.94	0.095
kw_roll4	최근 1시간 평균	0.88	0.91
최근2시간_전력최대	최근 2시간 최대 전력	0.86	0.91
kw_lag2	15분 전 전력	0.86	0.90
kw_lag8	1시간 45분 전 전력	0.67	0.75
과거전력_16칸	4시간 전 전력	0.48	0.59
is_weekend	주말 여부	0.24	0.35
kw_lag96	하루 전 같은 시각 부근 전력	0.10	0.25
생산량_lag4	한 시간 전 생산량(미사용)	0.18	0.25
풍속_lag4	한 시간 전 풍속 (미사용)	0.01	0.011
기온_lag4	한 시간 전 기온 (미사용)	0.0053	-0.0255
15분위치	15분 단위 순번(0~3)	0.0002	-0.0035

현재 전력 하나만으로 시험 구간 전력 변동의 95.4%가 설명되었다. 이는 15분 뒤 전력이 대부분 지금 전력과 비슷하다는 의미이다. 그러나 R^2 가 높다고 예측이 쉬운 것은 아니다. 직전 15분 구간의 전력 값을 그대로 다음 값으로 내는 방식도 시험 R^2 가 0.95이지만 MSE는 180.33으로, 최종 모델의


값 46.56의 약 4배이다. 즉 모델 간 성능의 차이는 R^2 로 설명되지 않는 나머지 5% 안팎, 특히 전력이 급하게 변하는 시점에서 결정된다고 해석할 수 있다.

3.2 예측오차 분석

3.2.1 오차 분포

본 절에서는 앙상블 모델의 오차 분포를 확인하였으며, 그 결과를 그림 9에 나타내었다. 그래프를 확인했을 때, 대부분의 예측은 실제값과 일치하는 대각선 근처에 있고, 오차 분포도 0을 중심으로 좁게 모여 있고 오차는 소수의 시점에 몰려 있는 것을 볼 수 있다. 이때, 시험 구간 절대오차의 95백분위인 13.99kW를 기준으로 이 값 이상을 ‘큰 오차’로, 미만을 ‘작은 오차’로 정의하였으며, 어느 쪽에도 해당되지 않는 값을 ‘나머지’로 정의하였다. 250행(5.01%)이 큰 오차에 해당하며, 이 250행이 전체 제공오차의 44.34%를 차지하였다. 큰 오차 행의 평균 절대오차는 18.84kW, 나머지 4,741행은 3.89 kW였다.

MSE는 오차를 제곱해 평균하므로 5%의 큰 오차에 크게 좌우된다. 따라서 성능을 크게 개선하기 위해서는 작은 오차보다는 큰 오차가 생기는 조건을 파악하는 것이 중요한데, 따라서 이를 시간대, 요일, 날짜, 부하 변화 조건별로 나누어 확인하였다. 가장 큰 오차는 9월 8일 12:00에 발생한 실제 0kW, 예측 106.96kW였다.




[그림 9] 최종 앙상블 모델의 예측값-실제값 비교, 오차분포, 큰 오차의 집중도

3.2.2 하루 중 시간대별 오차

오차를 예측 대상 구간 기준으로 하루 96개 15분 구간에 나누어 보면,


00:00~06:59의 평균 절대오차는 3.11kW였으나 07:00~19:59는 5.65 kW로 약 1.8배였다. MAE가 가장 큰 구간은 17:30~17:45(7.62kW), 12:45~13:00(7.51kW), 11:45~12:00(7.43kW), 15:15~15:30(6.99kW), 07:45~08:00(6.93kW), 08:00~08:15(6.81kW) 순이었다. 하루 96개 15분 구간별 평균 절대오차와 상위 16개 구간분석을 수행한 결과는 그림 10에 나타내었다.



[그림 10] 하루 96개 15분 구간별 평균 절대오차와 상위 16개 구간

3.2.3 요일, 날짜별 오차


요일 및 15분 구간별 평균 절대오차와 오차율 그래프는 그림 11에 나타내었다. 요일별로는 평일 MAE가 5.57kW, 주말이 2.34kW였으며, 큰 오차 250행 중 주말은 12행에 그쳤다. 평일 오전부터 저녁 시간에 짙은 칸이 모여 있고, 주말은 일부 시점을 제외하면 대부분 옅은 색이다.



[그림 11] 요일 및 15분 구간별 평균 절대오차(위)와 큰 오차율(아래)

3.2.4 대표 사례 해석

같은 사건이 반복해서 선택되지 않도록, 절대오차가 큰 순서로 서로 6시간 이상 떨어진 사례 6개를 골라 이전 2시간과 이후 2시간, 총 4시간의 실제값과 예측값을 비교하였으며, 실제 전력값과 예측 전력값을 나타낸 그래프를 그림 12에 제시하였다.



[그림 12] 대표 큰 오차 6건의 전후 실제 및 예측 전력

또한, 큰 오차가 발생하는 6가지 사례를 선정하여 3가지 유형으로 나누었으며, 그 결과를 표 5에 나타내었다.

첫째, 0kW로 급락하는 경우다. 9월 8일과 8월 28일이 해당한다. 학습 구간의 정답 범위는 19~222kW로 0kW가 한 번도 없었으나, 시험 구간에는 0kW가 74행 포함되어 있었다. 트리 계열 모델들은 원리상 학습 정답의 평균을 내기 때문에 학습구간의 최솟값보다 낮은 값을 내기 어렵고, 실제로 ExtraTrees의 예측 최솟값이 19.29kW였다. GRU는 0 근처에서 음수까지 예측했는데, 최종 앙상블 모델의 예측에서는 음수값이 발생하지 않았다.

둘째, 이미 시작된 상승과 하락이 다음 구간에서 커진 경우이다. 7월 31일, 9월 6일이 이에 해당한다. 직전 15분 변화는 각각 -23kW와 +20kW였으며, 다음 15분에는 각각 -59kW와 +76kW로 변화 폭이 커졌다. 모델은 전력의 변화가 추가적으로 강해지는 추세를 충분히 예측하지 못했다.

셋째, 평소 패턴과 다른 날이다. 8월 9일과 8월 29일이 이에 해당한다. 8월 9일에는 실제로는 부하가 유지되었으나 두 모델 모두 하락을 예측하였고, 8월 29일 일요일에는 0kW에서 갑자기 오른 직후 증가가 계속될 것으

로 예측하였다. 두 경우 모두 ExtraTrees와 GRU 두 단독 모델에서 오차의 방향이 동일하여 앙상블 모델이 오차를 상쇄시키는 데에 실패한 경우이다.

[표 5] 대표 큰 오차 사례의 관측 결과

대상 시각	직전 - 실제 (kW)	예측(kW)	관측 사실
09-08(수) 12:00	132 → 0	107.0	실제 0kW 급락, 예측은 107 kW
08-28(토) 17:30	41 → 0	47.9	급락 후 다음날 11:15까지 0kW 지속
07-31(토) 00:00	80 → 21	67.2	자정에 급감 후 저부하 지속
08-09(월) 17:00	173 → 169	123.4	실제 고부하 유지, 두 모델은 하락 예측
08-29(일) 11:45	41 → 25	68.3	급증 직후 실체는 감소, 예측은 증가
09-06(월) 08:00	81 → 157	125.8	실제 급증 폭을 과소예측

3.3 향후 추가 데이터 확보 및 프로젝트 확장 방향성

본 프로젝트에서 구축한 전력 예측 모델과 오류분석 결과를 바탕으로, 향후에는 생산, 설비, 운영 데이터를 연계하여 전력 변화의 해석과 예측 활용 범위를 넓힐 수 있다. 특히 예측 시점에 확보할 수 있는 계획 정보와 실제 운전 기록을 구분하여 활용하면 부하 변화의 사전 예측과 사후 원인 분석을 함께 발전시킬 수 있다.

- 설비별 전력, 작업일지, 계측기록 확보 및 연계 : 주요 설비의 개별 전력, 가동 상태, 동시 운전, 정비 기록 및 계측기 상태 정보 등을 수집하면 공장 전체 부하를 구성하는 요인을 구체적으로 분석할 수 있다. 이를 바탕으로 부하가 집중되는 원인을 정확히 파악하고, 특히 전력 급변과 0kW 관측의 발생 배경을 구분할 수 있다. 또한 설비 시동 순서나 작업 시간을 조정하는 방안을 추가적으로 검토할 수 있으며, 상황에 맞는 예측 기준이나 데이터 처리 기준을 유연하게 적용할 수 있다.

- 계절과 운영 조건을 포괄하는 데이터 축적: 겨울철을 포함한 연중 자료와 다양한 생산량, 설비 가동 조건의 데이터를 수년간 축적하면, 계절과 운전 환경에 따른 예측 특성을 비교할 수 있다. 모델과 앙상블 비율을 고정한 뒤 새롭게 수집한 기간을 평가하는 방식으로 운영 환경에서의 성능을 검증하고, 모델 갱신 주기를 구체화할 수 있다.
- 피크 대응과 비용 분석: 최대수요전력과 요금 적용 기준, 실제 배치 인원과 근무일지, 작업별 소요 시간, 전력 요금을 제외한 다른 비용의 종류와 규모, 점심시간 교대 등의 자료를 연계하면 전력 예측을 작업 일정을 조정하거나 비용을 검토하는 방향으로 확장할 수 있다. 이를 통해 공정 담당자가 전력 피크가 발생할 가능성을 파악하고 여유 있는 대응을 할 수 있도록 지원할 수 있다.

이러한 데이터 확장이 가능하다면 단순히 전력 사용량을 예측하는 데 그치지 않고, 전력 부하 변화의 원인을 파악할 수 있게 하고 운영 방안을 제시할 수 있는 기반이 될 것이다.


□ 제4장. 현장 활용방안

본 프로젝트에서는 ExtraTrees와 GRU 앙상블 모델의 예측 결과를 공정 운영에 직접 활용할 수 있도록 대시보드를 구현하였다. 본 대시보드는 크게 전력관제, 자원 최적화 탭으로 구분되어 있으며, 사용자로 하여금 각각의 탭에서 전력사용 현황을 확인하고 투입인원을 최적화할 수 있도록 한다. 이를 통해 현장에서의 신속한 의사결정을 돕고, 모델의 예측 결과에 기반한 효율적인 자원 배분과 운영비용 절감을 지원할 수 있을 것으로 기대된다.

4.1 전력사용 의사결정 지원

전력 관제 탭에서는 현재 전력, 다음 15분 구간의 예측 전력, 알림 기준까지의 여유 전력을 확인할 수 있도록 대시보드를 구성하였다. 실제 전력과 예측 전력을 동일선상에 표시하며, 예측값이 알림 기준 이상이면 경보

와 예상 초과량을 표시하여 사용자로 하여금 신속하게 의사결정을 내릴 수 있도록 도움을 준다. 또한, 직전 15분 전의 생산량과 기상정보를 함께 제공하여 생산 공정 현황과 전력 흐름을 확인할 수 있도록 하였다. 전력 관제 탭의 메인 페이지는 그림 13에 나타내었다.



[그림 13] 전력 관제 탭의 메인 페이지

4.2 생산계획에 따른 인력 및 운영비용 검토

자원 최적화 탭은 해당 시간의 실제 생산량을 실적 목표로 불러와 이를 기준으로 투입 인원과 예상 비용을 확인하여 사용자가 직접 인원관리 및 운영비용 설정을 수행할 수 있도록 하였다. 계산에는 해당 시점 기준 다음 정각의 예측 전력값을 사용하며, 이후 한 시간 동안의 생산 이익과 운영비를 표시한다. 대시보드에 사용된 인자값들의 산정식은 표 6에 나타내었으며, 자원 최적화 탭의 메인페이지는 그림 14에 나타내었다.

[표 6] 전력 수준과 부하 전환 조건별 오차

분류	산정 방식
인원	대상 날짜보다 이전의 기록 중 시간 및 평일/휴일 구분이 일치하는 데이터 중, 목표 생산량 이상을 달성한 인원의 최솟값
생산 이익	시간당 생산 목표 × 개당 생산 이익
인건비	참고 인원 × 시간당 시급 (22:00~06:00에는 1.5배)
예측 전력 요금	정시 예측 전력 × 1시간 × 계절, 부하별 단가
기본 요금 배분	작년 피크 전력 × 기본요금 단가 ÷ 해당 월 일수 ÷ 24
시간당 영업 이익	생산 이익 - 인건비 - 전력 요금 - 기본요금 배분

⚡ 전력 모니터링 대시보드

전력 관제 | 자원 최적화

재생 날짜: 2021-07-25 | 알림 기준

2021.07.25 12:00

실적 목표

0 개

12:00~13:00 - 휴일

현재 추천 인원

0 명

12:00~13:00 - 휴일

계산 조건

정시 예측 전력: kW

적용 시간: 시간

11:45 → 12:00 예측

12:00~13:00

생산 이익: 원/개

인건비: 원/명-시간

☒ 기본값

☒ 기본값

기본 요금: 원/kW

전력량 단가: 원/kWh

작년 피크 전력: kW

☒ 기본값

적용 **초기화**

계산 결과

예상 생산 이익: **0원**

예상 이익: **0원**

인건비: 0명 **0원**

전력량요금: **1,400원**


기본요금 1시간 배분: **1,941원**

예상 운영비: **3,341원**

[그림 14] 자원 최적화 탭의 메인페이지

4.3 AI 브리핑 및 질의 응답

마지막으로 전력 상태와 예측 결과를 자연어로 전달하는 AI 브리핑 기능을 구현하였다. OpenAI API 키가 입력되면 관측 정보와 모델 예측 결과를 바탕으로 상황을 설명하고, API 키가 없으면 미리 정해놓은 규칙에 기반한 요약を提供한다. 브리핑은 현재 전력 상태, 다음 15분 예측, 권장 관리 방안, 판단 근거와 한계로 구성되며, 과거 데이터를 15분 단위로 조회할 때 자동으로 갱신하거나 사용자가 직접 갱신할 수도 있다. 전력 예측과 수치 계산은 저장된 모델과 계산 함수가 수행하고, 언어 모델은 관측 사실과 예측을 구분하여 설명한다. 또한 질의응답과 음성 읽기, 피크 위험 시 자동 음성 알람을 지원한다. AI 브리핑의 메인 페이지는 그림 15에 나타내었다.



[그림 15] AI 브리핑의 메인 페이지

□ 제5장. 창의성 및 차별성

5.1 서로 다른 학습 방식을 결합한 전력 예측 모델

본 프로젝트에서는 전력 데이터의 특성에 맞는 모델을 단계적으로 검토하였으며, 최종적으로 트리 계열에서 분할 기준에 무작위성을 더한 ExtraTrees와 순환신경망 계열인 GRU를 앙상블하였다.

ExtraTrees는 과거 전력의 시차값, 변화량, 이동 통계와 시간 정보 사이의 관계를 학습하고, GRU는 연속된 전력 관측의 흐름을 학습했기 때문에, 단순히 개별 모델을 선택하는 것이 아니라 동일한 전력 이력을 서로 다른 방식으로 학습한 결과를 결합하는 것을 시도하였으며, 실제로 큰 폭으로 예측 오차를 줄이는 데 성공했다. 본 프로젝트의 차별성은 모델의 복잡성을 높이는 데 그치지 않고, 서로 다른 학습 방식의 결합 효과를 실제 평가 결과로 확인한 데 있다.

5.2 앙상블 효과의 해석과 오차 심층 분석

본 프로젝트는 앙상블의 성능을 개선시키기 위해 두 모델의 오차가 어떤 관계를 보이는지 심층적으로 분석하였다. 두 모델의 오차 부호는 평가 관측 범위의 약 75%에서 같았다. 이는 앙상블의 효과가 서로 반대 방향으로 발생한 오차의 상쇄만으로 설명하기 어렵다는 점을 보여 준다.

같은 부호의 오차가 발생하더라도 모델별 오차의 크기는 다를 수 있다. 이러한 경우 결합 예측은 두 예측값 사이에 위치하므로, 해당 시점에서 오차가 더 큰 모델의 영향을 완화할 수 있다. 구간마다 상대적으로 정확한 모델이 달라지는 상황에서는 이러한 결합이 전체 평균 오차를 줄이는 데 기여할 수 있다.

또한 15분 단위의 시간대, 부하 수준 여부에 따라 오차를 구분하여 앙상블이 효과를 보이는 조건과 오차가 집중되는 조건, 오차가 상대적으로 적은 조건들을 함께 제시하였다. 이를 통해 모델 선택을 하나의 평균 점수로 판단하는 데서 확장하여, 데이터의 상태에 따라 모델의 예측 특성이 어떻게 달라지는지 설명하였다.


5.3 공정 관리 대시보드와 AI 챗봇 시스템

본 프로젝트는 단순 모델링에 그치지 않고, 해당 모델을 담당자가 활용할 수 있도록 현재 전력, 다음 15분 예측 전력, 알림 기준까지의 여유를 한 화면에서 확인할 수 있는 대시보드를 구현하였다. 특히 실제값이 확인된 과소예측 오차를 알림 기준에 반영하여, 예측값을 제시하면서도 담당자가 피크 전력까지 여유 있는 수준에서 전력을 관리할 수 있도록 제공하였다.

AI 기능은 전력 상황을 요약하는 브리핑과 공정에 대한 질의응답을 함께 제공한다. 브리핑은 현재 상태와 다음 구간의 위험, 확인 사항 및 대응 후보를 정리하며, 담당자는 질의응답을 통해 공정에 관한 궁금한 점과 운영 시 고려할 사항을 추가로 질문하고 조언을 얻을 수 있다. 전력 예측과 비용 계산은 저장 모델과 계산 함수가 담당하고, 언어 모델은 산출 결과의 설명과 질문에 대한 응답을 담당하도록 구성하였다. 이를 통해 담당자가 예측 결과를 확인한 뒤 필요한 정보를 대화로 탐색할 수 있도록 하였다.

□ 제6장. 코드 구성 및 재현성

6.1 프로젝트 폴더 및 파일 구성



[그림 16] 프로젝트 폴더 구조

프로젝트에는 총 네 개의 폴더가 존재한다.

Dataset : raw data 및 preprocessed data

Function : 기능 관련 python code

Model : 모델링 파일 및 예측 CSV 파일

Dashboard : 서버 및 대시보드 관리 파일

전체적인 진행 플로우는 다음과 같다.

1. raw data를 전처리하여 preprocessed data를 생성
2. preprocessed data를 활용하여 모델 학습 후 모델 파일 생성
3. raw data와 preprocessed data 및 json 파일들에 입력된 값들로 자원 최적화 계산식 구성
4. 챗봇을 대시보드에 연결(OpenAI API 활용)
5. 구성된 것들을 모두 연결하여 대시보드 구성

모델링 관점에서 주요 파일들을 다시 정리하면

Dataset/raw/okm_augumented_2021.csv : raw data

Dataset/preprocessed/processed.csv : preprocessed data

Function/model_training.py : 모델 학습

Model/model_et.joblib : ExtraTrees 모델 파일

Model/test_predictions.csv : 예측 csv 파일

Model/model_gru.pt : GRU 모델 파일

6.2 실행 방법

실행은 프로젝트 최상위 폴더에서 시작한다. 검증 환경은 다음과 같으며 모델 호환성을 위해 requirements.txt에 사용한 버전들을 기록해두었다.

- Python 3.11.17
- Node.js 24.9.0
- npm 11.6.0
- macOS arm64

6.2.1 환경 준비

```
python3.11 -m venv .venv
```

```
source .venv/bin/activate
```

```
python -m pip install -r requirements.txt
```

6.2.2 데이터 전처리

```
python Function/data_preprocessing.py
```

전처리는 시간 오류, 결측, 중복 열을 처리하고 15분 단위 모델 입력을 생성한다. 결과는 Dataset/preprocessed/processed.csv에 저장한다.

6.2.3 모델 학습 및 지표 평가

```
python Function/model_training.py --models et,gru,ensemble
```

전처리 완료 후 프로젝트 최상위 폴더에서 실행한다. ExtraTrees와 GRU를 학습하고 앙상블을 평가하며, 완료 후 Model/의 저장 모델과 평가 기록을 갱신한다.

실행 종료 시 터미널에 모델별 전진검증 평균 MSE와 시험 MSE가 출력된다. 상세 지표는 Model/results.json의 “모델별” 에서 et, gru, ensemble을 선택하여 “시험” 의 MSE, MAE, RMSE, R^2 를 확인한다.

6.2.4 추론 및 대시보드 실행

```
cd Dashboard
```


```
npm ci
```

```
npm run dev
```


□ 경진대회 만족도 조사 완료 페이지 캡처화면

- 만족도 조사 url : <https://naver.me/FetWt7SN>

1. 정병근



2. 최강현



3. 박한샘

